

Seminario de Tecnologías de Información lo

Proyecto: Banco de peces

INTEGRANTES:

González Rodríguez José
Alberto

Martinez Barrales Oscar
Mejía García Oswaldo

Profesor: Rudomin
Goldberg Isaac Juan

Reporte de lectura: “Skeletal-Driven Animation of Anatomical Humans via Neural Deformation Gradients”

Nolte, G., Kemper, F., Schwanecke, U. y Botsch, M. (2026). Computer Graphics Forum.

Introducción

Animar un cuerpo humano digital suena, en principio, a un problema resuelto: los videojuegos y las películas lo hacen todos los días. El truco es que casi todas esas técnicas solo mueven la piel. En cuanto se intenta animar también el músculo y el hueso por debajo, para fines médicos, deportivos o simplemente para que un personaje se doble de forma creíble, los métodos tradicionales empiezan a fallar: las articulaciones colapsan, los huesos se asoman a través de la piel, o el volumen del cuerpo cambia de manera poco realista.

El artículo de Nolte, Kemper, Schwanecke y Botsch, publicado en Computer Graphics Forum como parte de Eurographics 2026, propone una salida a ese problema mediante una red neuronal que aprende a predecir gradientes de deformación en vez de posiciones de vértices. El resultado, al que llaman Neural Deformation Gradients (NDG), logra animar hueso, músculo y piel de forma coordinada, a velocidades interactivas (25 a 30 cuadros por segundo) y con una fidelidad cercana a la de una simulación física completa, que normalmente tardaría segundos o minutos por cuadro.



Figura 1: Cinco instancias de un mismo cuerpo animado con NDG. Los modelos de los extremos muestran solo la piel (sin protrusiones visibles); los intermedios muestran músculo y hueso; el central, solo el esqueleto. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

El problema que atacan

Los autores dividen las técnicas existentes en dos familias, cada una con un defecto distinto. Por un lado están los métodos de skinning geométrico, como Linear Blend Skinning (LBS) o Dual Quaternion Skinning (DQS), que son muy rápidos pero no tienen ninguna noción real de anatomía interna: si se les pide animar hueso y músculo junto con la piel, producen intersecciones y protrusiones porque nada les impide que una capa se meta dentro de otra.

Por otro lado están las simulaciones físicas basadas en el método de elementos finitos (FEM), que sí resuelven este problema porque calculan cómo se comportan realmente los tejidos, respetando volumen y evitando colisiones internas. El costo es que una sola pose puede tardar varios segundos o minutos en resolverse, lo cual las vuelve inservibles para cualquier aplicación en tiempo real.

La apuesta del paper es quedarse con la calidad de la simulación física pero acelerarla varios órdenes de magnitud usando una red neuronal entrenada precisamente sobre esas simulaciones.

El modelo anatómico por capas

Antes de entrenar nada, los autores necesitan una representación consistente del cuerpo. Construyen un modelo volumétrico con tres capas conectadas entre sí: una malla de piel, una envoltura de músculo y una envoltura de hueso, todas con la misma tesela (es decir, se corresponden vértice a vértice). El espacio entre capas se llena con prismas triangulares, que terminan siendo la unidad básica sobre la que se calcula la deformación. Cabeza, manos y pies quedan fuera de este esquema volumétrico porque tienen poco volumen interno relevante, y se animan aparte con LBS convencional.



Figura 2: Mallas plantilla del modelo. A la izquierda, las envolturas de piel (azul), músculo (rojo) y hueso (amarillo) que comparten teselación. A la derecha, la piel junto con las mallas anatómicas de alta resolución del músculo y el hueso. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

Sobre esta estructura corren simulaciones FEM con energías elásticas del tipo Neo-Hookeano estable para el músculo y la grasa, y energías de tipo “discrete shells” para que la piel se doble de forma suave y sin estirarse artificialmente. Esa simulación es la que genera los datos de entrenamiento: alrededor de 1,500 cuerpos distintos tomados del conjunto CAESAR y 15,000 poses obtenidas de bases de captura de movimiento como AMASS, combinadas para producir 20,000 ejemplos de entrenamiento, 2,500 de validación y 2,500 de prueba, con cuerpos y poses estrictamente separados

entre conjuntos para evitar fugas de información.



Figura 3: Cuatro cuerpos distintos generados por la simulación FEM de los autores, mostrando cómo la musculatura y el esqueleto de alta resolución se deforman mientras permanecen contenidos dentro de la piel. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

Por qué predecir gradientes y no posiciones

Aquí está la idea central del paper, y vale la pena detenerse en ella. La mayoría de los métodos neuronales previos predicen desplazamientos de vértices: para cada punto de la malla, la red dice cuánto moverlo. El problema es que, en elementos delgados como los prismas de músculo o grasa, un desplazamiento pequeño y aparentemente inofensivo puede voltear el elemento por dentro, generando volumen negativo y, con ello, huesos o músculos que se asoman a través de la piel.

En cambio, NDG predice el gradiente de deformación de cada prisma, una matriz que describe cómo se estira y rota localmente el material. Para garantizar que ningún elemento se invierta, la red aplica una exponencial matricial como última capa, lo que asegura matemáticamente que el determinante de cada gradiente predicho sea positivo. Dicho de otro modo: la arquitectura

hace físicamente imposible que la red proponga un elemento con volumen negativo, en lugar de simplemente penalizarlo durante el entrenamiento.




Figura 4: Pipeline de cómputo de NDG: la forma del cuerpo ($\mathbf{b}$) y la pose ($\mathbf{r}$) alimentan la red, que produce deformaciones residuales; estas se combinan con las rotaciones inducidas por el esqueleto y se resuelven mediante un sistema de Poisson, usando la malla del hueso (LBS) como restricción de Dirichlet. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

Una vez que la red produce esos gradientes residuales, la posición final de los vértices se recupera resolviendo un sistema de Poisson, un problema de mínimos cuadrados que encuentra la malla cuya deformación se ajusta mejor a los gradientes predichos. La matriz de ese sistema depende solo de la malla en reposo, así que puede prefactorizarse una sola vez y reutilizarse en cada cuadro, lo cual es clave para mantener el método rápido.

La red en sí es un perceptrón multicapa relativamente sencillo: tres capas ocultas (4096, 4096 y 600 neuronas) con normalización de capa y activación GeLU, que recibe como entrada la pose (rotaciones de 60 articulaciones) y una codificación PCA de 300 dimensiones de la forma corporal en reposo. Entrenarla toma alrededor de dos horas en una GPU RTX 6000.




Figura 5: Arquitectura de la red NDG. La forma corporal (300 dimensiones vía PCA) y la pose (540 dimensiones) se concatenan y pasan por cuatro bloques densos con normalización de capa y GeLU; la exponencial matricial garantiza deformaciones residuales con determinante positivo. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

Vale la pena notar que el resultado de este proceso ya es una animación visualmente convincente en cuerpos muy distintos entre sí, no solo en el promedio del conjunto de entrenamiento.




Figura 6: Animación con NDG en cuerpos diversos: fila superior con IMC mayor a 30, fila inferior con IMC menor a 23; columna izquierda cuerpos masculinos, columna derecha femeninos. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

Qué tan bien funciona

Los autores comparan NDG contra varias alternativas: una red neuronal equivalente pero basada en desplazamientos de vértices (a la que llaman VertexNet), LBS puro, projective skinning, elasticidad lineal co-rotada, y dos modelos anatómicos recientes de la literatura, SKEL y HIT.

Los resultados numéricos favorecen consistentemente a NDG. Frente a VertexNet, reduce a más de la mitad el número de elementos invertidos y disminuye en un factor de tres el error tanto en gradientes de deformación como en preservación de volumen, con una precisión de posición ligeramente mejor.



Figura 7: Precisión por vértice de VertexNet y NDG. Para cada vértice de la piel se visualiza la distancia promedio hasta su posición objetivo. NDG obtiene un error de 1.81 mm frente a 2.27 mm de VertexNet. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

La diferencia se nota más en poses de estiramiento fuerte, donde VertexNet produce intersecciones visibles entre músculo y piel mientras NDG las evita.




Figura 8: Bajo una pose de estiramiento exigente, los músculos predichos por VertexNet (izquierda, marcados en rojo) intersectan la piel; NDG (derecha) evita esas intersecciones incluso en este caso difícil. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

La preservación de volumen es otro punto donde se nota la diferencia entre representar la deformación como desplazamientos o como gradientes. La simulación FEM es, como era de esperarse, la que mejor preserva el volumen; NDG se acerca bastante a ese comportamiento, mientras que los métodos físicos simplificados (projective skinning y elasticidad lineal co-rotada) y los métodos sin red neuronal (LBS, gradient skinning) muestran cambios de volumen mucho más marcados.




Figura 9: Cambio relativo de volumen local para siete métodos frente a la simulación FEM de referencia. NDG (c) se mantiene muy cerca de FEM (d); los métodos físicos simplificados (b, f) y los que no usan red neuronal (a, e) muestran mayores desviaciones; VertexNet (g) presenta más error que NDG. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

Frente a SKEL y HIT, que representan huesos y tejidos sin ninguna restricción explícita de no penetración, NDG logra mantener toda la anatomía interna dentro de los límites de la piel; SKEL y HIT, en cambio, presentan penetraciones en el cien por ciento de los cuadros evaluados por los autores.




Figura 10: Comparación cualitativa: en HIT (a, e) el tejido óseo y muscular reconstruido interseca la piel; en SKEL (b, f) el esqueleto penetra la piel en la caja torácica y las piernas; NDG (c-d, g-h) mantiene las estructuras internas dentro de la piel. Fuente: Nolte, Kemper, Schwanecke y Botsch (2026), reproducida bajo licencia CC BY-NC.

Un experimento que me parece particularmente honesto es la prueba fuera de distribución: los autores toman un cuerpo generado por un artista, con proporciones estilizadas que no aparecen en los datos de entrenamiento (basados en escaneos reales), y evalúan ambas redes sobre él. VertexNet

se degrada fuertemente, con un salto grande en inversiones y pérdida de volumen. NDG, en cambio, mantiene un desempeño mucho más cercano al que tiene con datos conocidos. Es el tipo de prueba que demuestra si una arquitectura realmente aprendió algo generalizable o si solo memorizó patrones del conjunto de entrenamiento, y aquí NDG sale bien parado.




Figura 11: Al enfrentar un cuerpo fuera de la distribución de entrenamiento, VertexNet (izquierda) produce protrusiones visibles con mucha más frecuencia; NDG (derecha), basado en gradientes de deformación, se mantiene robusto. Fuente: Nolte, Kemper, Schwanke y Botsch (2026), reproducida bajo licencia CC BY-NC.

En cuanto a velocidad, el método completo corre en 25 a 30 cuadros por segundo en hardware de consumo: entre 5 y 7 milisegundos para la inferencia de la red en una GPU y entre 20 y 25 milisegundos para el sistema de Poisson en CPU. Es más lento que LBS puro, como es de esperar, pero más rápido que projective skinning o la elasticidad lineal co-rotada, y sin el problema de pérdida de volumen que arrastran esos dos métodos.

Limitaciones que los propios autores señalan

Es de agradecer que el artículo dedique espacio real a sus límites en vez de despacharlos en una línea. El hueso se sigue animando con LBS convencional, así que no es perfectamente rígido, algo que en teoría debería serlo. Cabeza, manos y pies quedan fuera del modelo volumétrico, lo que

puede generar artefactos menores en esas zonas. La colisión entre partes del cuerpo (por ejemplo, un brazo contra el torso) no está modelada en los datos de entrenamiento, así que el método hereda esa limitación. Y como no existe ground truth anatómico real y detallado para poses diversas, todo el entrenamiento depende de simulaciones FEM, que son una aproximación y no una medición directa del cuerpo humano.

Conclusión

Lo que más me convence de este trabajo es la elección de representación: en vez de pedirle a la red que adivine dónde debe ir cada vértice, le piden que aprenda cómo se deforma localmente el material, y luego dejan que un sistema de Poisson, matemáticamente bien entendido, reconstruya la malla. Es una división de trabajo sensata entre lo que una red neuronal hace bien (aprender patrones complejos de deformación a partir de datos) y lo que un solver clásico hace mejor (garantizar consistencia geométrica global).

El resultado no es solo una mejora incremental de precisión, sino una diferencia cualitativa: mientras los métodos previos basados en vértices o en modelos como SKEL y HIT prácticamente siempre producen penetraciones entre capas anatómicas, NDG las evita casi por completo, y lo hace a una velocidad compatible con aplicaciones interactivas. Para campos como la visualización médica, la biomecánica deportiva o los videojuegos con anatomía visible, esa combinación de velocidad y consistencia física es exactamente lo que hacía falta. Queda pendiente, como los mismos autores reconocen, resolver la rigidez del hueso y las colisiones entre extremidades, pero el marco general parece lo bastante sólido como para incorporar esas mejoras sin rediseñarlo desde cero.

Referencia

Nolte, G., Kemper, F., Schwanecke, U., y Botsch, M. (2026). Skeletal-driven animation of anatomical humans via neural deformation gradients. *Computer Graphics Forum*, e70388. <https://doi.org/10.1112/cgfs.12345>

[//doi.org/10.1111/cgf.70388](https://doi.org/10.1111/cgf.70388)